


Árboles de decisión

Cómo aprende, predice y se evalúa

Caso: 480 observaciones simuladas y un árbol reproducible.



Un árbol aprende una secuencia de preguntas



Idea central

Cada división busca grupos más homogéneos; cada hoja entrega una predicción.

La respuesta determina el tipo de árbol

Clasificación

Predice una **categoría**.

- ▶ riesgo alto o bajo;
- ▶ diagnóstico A, B o C;
- ▶ evento sí o no.

Criterios habituales: Gini o entropía.

Regresión

Predice una **cantidad continua**.


- ▶ concentración;
- ▶ tiempo de estancia;
- ▶ costo esperado.

Criterio habitual: reducción del error cuadrático.

Nuestro ejemplo es de **clasificación binaria**: `riesgo_alto` vale 0 o 1.

Raíz, nodos, ramas y hojas forman reglas legibles

Arbol entrenado: profundidad maxima = 3



Verdadero → izquierda · Falso → derecha · En la hoja, class es la predicción.

Gini mide cuánta mezcla queda en un nodo

Impureza de Gini

$$G(t) = 1 - \sum_{k=1}^K p_{k,t}^2$$

El árbol compara preguntas y conserva la que produce la **mayor reducción de impureza**.

Nodo puro: $G = 0$



Mezcla 50/50: $G = 0.5$



Dos hijos puros: $G_{div} = 0$




Separar antes de aprender protege la evaluación



Regla práctica

El conjunto de prueba no debe decidir variables, umbrales ni profundidad.

El caso usa datos simulados y un árbol pequeño




Seis predictores

- ▶ edad y presión sistólica;
- ▶ colesterol;
- ▶ fumador;
- ▶ actividad semanal;
- ▶ antecedente familiar.

Profundidad máxima: 3
Hojas resultantes: 8

La exactitud mejora, pero se pierden positivos



0.733

Exactitud

0.794

Precisión

0.519

Sensibilidad


0.724

ROC AUC

Referencia por clase mayoritaria: **0.567**.

Hay 25 falsos negativos: la exactitud por sí sola no basta.

Más profundidad mejora el ajuste, no siempre la generalización



Controlar complejidad

- ▶ limitar profundidad;
- ▶ exigir hojas más grandes;
- ▶ podar ramas;
- ▶ validar parámetros.

Señal: entrenamiento mejora; prueba se estanca.

Interpretabilidad no significa confiabilidad automática

Lo que ofrece

- ▶ reglas visuales y comunicables;
- ▶ relaciones no lineales;
- ▶ interacciones entre variables;
- ▶ clasificación y regresión.

Lo que exige

- ▶ control del sobreajuste;
- ▶ evaluación externa;
- ▶ revisión de sesgos;
- ▶ distinguir predicción de causalidad.

En contextos clínicos

Transparencia, validación, calibración y juicio profesional siguen siendo indispensables.

Tres ideas para llevarse

1. Un árbol aprende preguntas que dividen los datos en grupos más homogéneos.
2. La evaluación debe usar observaciones que no participaron en el aprendizaje.
3. Una regla legible sigue necesitando validación y uso responsable.

Del árbol al notebook

El repositorio permite reproducir datos, código, figuras y resultados paso a paso.

Lecturas: Breiman, Friedman, Olshen y Stone (1984), *Classification and Regression Trees*. Ma (2018), *Using Classification and Regression Trees*, cap. 3.